

Cours rédigé par :


Mathieu SEURIN

mathieu.seurin@devinci.fr

Nancy CHENDEB


nancy.chendeb@devinci.fr

ALGORITHMES D'APPRENTISSAGE: CHAPITRE 2 : ACP



INTRODUCTION

- Objectifs de l'ACP
- Principe
- Étapes
- Mesures d'évaluation
- Avantages et inconvénients



APPRENTISSAGE NON-SUPERVISÉ

Taille		Prix
25	→	275k
100		400k

X

y

Supervisé (CM3)

Taille	Prix des voisins
25	100k
100	200k

X

Non-Supervisé

Non supervisé :

- Clustering (DBScan, Kmeans)
- Dimension Reduction ou Datavisualization (vers 3D ou 2D) (T-SNE)
- Self-supervised

\ ANALYSE EN COMPOSANTES PRINCIPALES

- Conçue pour la première fois par Karl Pearson en 1901

Objectif

- Réduire la dimensionnalité
 - Exemple : Donner une représentation visuelle d'un large ensemble de données
- Transforme les variables d'origine corrélées en des variables non corrélées (composantes principales)


ANALYSE PAR COMPOSANTE PRINCIPALE DÉROULEMENT DE L'ALGO

- Calcul des « meilleurs » vecteurs de projection des données
- Projette l'ensemble de donnée dans un espace de plus faible dimension
- Fonction de coût / objectif : Préservant le maximum de variation.

Mais pourquoi faut-il préserver les variations?

\ PRÉSERVER LES VARIATIONS

	Height (cm)	Weight (kg)
Andrew	150	71
Nick	170	73
Jonas	140	70




Si vous supprimiez la colonne de poids , il est probable que vous puissiez toujours identifier ces individus uniquement en fonction de leur taille.


Si vous supprimiez la colonne de taille , vous auriez probablement du mal à les identifier.

OBJECTIFS

Définir p nouvelles variables (axes) avec $p < k$ qui feront perdre le moins d'information possible



Ici $k=2$ et x_1 et x_2 sont corrélées entre elles




2D data

x'_1 et x'_2 sont non corrélées entre elles.



On projette nos données



1D data


=> et passer de 2D à 1D tout en conservant leurs variations. ($p=1$)

COMPOSANTES PRINCIPALES

Les composantes principales représentent les directions dans lesquelles les données varient le plus.


L'idée est donc de trouver les premières composantes qui capturent la majorité de la variance des données, permettant une représentation plus concise.

=> trouver les axes de projections qui conservent le maximum de variabilité des données.



PROJECTION

- La projection orthogonale est déformante !!
 - Perdre le moins d'information possible nécessite une « bonne » projection qui déforme le moins possible le nuage d'origine
 - Plus le point est proche du plan de projection, plus on est proche de la « réalité »
- ⇒ Il faut choisir un sous espace de projection qui passe au plus proche de tous les points



RAPPEL NOTATION JEU DE DONNÉES

	x_0	x_1	
	Taille en m2	Terrasse	Prix des voisins
$x^{(0)}$	25	0	275k
	100	0	400k
	110	0	500k
	175	1	700k
$x^{(5)}$	200	1	750k

X

$$n = 5$$

Nombre d'exemples

$$k = 3$$

Nombre de
caractéristiques

RAPPEL NOTATION JEU DE DONNÉES

	x_0	x_1	
	Taille en m2	Terrasse	Prix des voisins
$x^{(0)}$	25	0	275k
	100	0	400k
	110	0	500k
	175	1	700k
$x^{(5)}$	200	1	750k

X

Une projection (linéaire dans ce cas-ci) ressemblera à :

$$c_0 = u_0x_0 + u_1x_1 + u_2x_2$$

$$\vec{u} = [u_0, u_1, u_2]$$

Si on veut 2 dimensions, on aura donc 2 vecteurs $\vec{u}$

QUELLE PROJECTION CHOISIR ?

Soit la projection de $\vec{x}$ sur l'axe $\vec{u}$

⇒ Il faut choisir un axe de projection $\vec{u}$ qui minimise MM'

Or d'après Pythagore:

$$\underbrace{OM^2}_{\text{constante}} = \underbrace{MM'^2}_{\text{à minimiser}} + \underbrace{OM'^2}_{\text{ou à maximiser}}$$

⇒ Minimiser $MM'^2 \Leftrightarrow$ maximiser OM'^2


$$\Leftrightarrow \text{maximiser } (\vec{x}^T \vec{u}). (\vec{x}^T \vec{u})$$

$$\Leftrightarrow \text{maximiser } (\vec{u}^T \vec{x}). (\vec{x}^T \vec{u})$$

$$\Leftrightarrow \text{maximiser } \vec{u}^T (\vec{x} \vec{x}^T) \vec{u}$$

$$\Leftrightarrow \text{maximiser } \underbrace{\sum_{i=1}^n \frac{1}{n-1} \vec{u}^T (\vec{x}_i \vec{x}_i^T) \vec{u}}_{\text{Inertie}}$$

car prod scalaire commutatif



$$\vec{x}' = \text{proj}_{\vec{u}} \vec{x}$$

$$OM' = \vec{x}^T \vec{u}$$

$$\vec{x}' = (\vec{x}^T \vec{u}). \vec{u}$$

Inertie

INERTIE: VARIANCE DES DONNÉES

On cherche donc les axes qui maximisent l'inertie totale donnée par la formule suivante:

$$I = \sum_{i=1}^n \frac{1}{n-1} \vec{u}^T (\overrightarrow{x^{(i)}} \overrightarrow{x^{(i)}}^T) \vec{u}$$

$\Leftrightarrow$

$$I = \vec{u}^T V \vec{u}$$

Où :

$$V = \frac{1}{n-1} X X^T \quad \text{et } X \text{ est un tableau de taille } n \times k$$

$x_0^{(0)}$	$x_1^{(0)}$	$x_2^{(0)}$
$x_0^{(1)}$	$x_1^{(1)}$	$x_2^{(1)}$
$x_0^{(2)}$	$x_1^{(2)}$	$x_2^{(2)}$

STANDARDISATION DES DONNÉES

La standardisation des données, également appelée centrage-réduction ou mise à l'échelle des données

Elle est un processus consistant à transformer les variables pour qu'elles aient une **moyenne nulle** et un **écart-type unitaire**.

Mathématiquement, il suffit de les centrer et réduire les données:

$$Z = \frac{x - \bar{X}}{S}$$

où:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n x_i \quad \text{la moyenne de } X$$

$$S = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{X})^2} \quad \text{l'écart type de } X$$

POURQUOI STANDARDISER LES DONNÉES?

Mise à la même échelle: Les variables qui ont des valeurs numériques plus élevées auront une influence disproportionnée sur l'analyse de PCA

Utile également quand on parlera de descente de gradient!

Taille en m2	Terrasse	Prix des voisins
25	0	1M
100	0	1.001M
110	0	0.999M
175	1	1M

INERTIE ET MATRICE DE COVARIANCE

Après standardisation la matrice n'est autre que la matrice des variances-covariances:

Où:

$$\Sigma = \begin{bmatrix} \text{var}(X_1) & \text{cov}(X_1, X_2) & \cdots & \text{cov}(X_1, X_p) \\ \text{cov}(X_2, X_1) & \text{var}(X_2) & \cdots & \text{cov}(X_2, X_p) \\ \vdots & \vdots & \ddots & \vdots \\ \text{cov}(X_p, X_1) & \text{cov}(X_p, X_2) & \cdots & \text{var}(X_p) \end{bmatrix}$$

$$\text{var}(X_i) = \frac{1}{n-1} \sum_{k=1}^n (x_{ik} - \bar{X}_i)^2$$

$$\text{cov}(X_i, X_j) = \frac{1}{n-1} \sum_{k=1}^n (x_{ik} - \bar{X}_i)(x_{jk} - \bar{X}_j)$$

COVARIANCE DE DEUX VARIABLES

La covariance mesure la force de la variabilité conjointe entre deux variables, indiquant dans quelle mesure elles changent les unes par rapport aux autres.

La valeur de la covariance peut être positive, négative ou nulle.

- Positif : à mesure que x_1 augmente, x_2 augmente également.
- Négatif : à mesure que x_1 augmente, x_2 diminue également.
- Zéros : aucune relation directe

$$\text{cov}(x, y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}).$$

OPTIMISATION DE LAGRANGE

Le but de l'ACP est de trouver les vecteurs unitaires et orthogonaux qui maximise l'inertie:

$$I = \vec{u}^T V \vec{u}$$

$$\max_{\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_k} \sum_{i=1}^k \mathbf{u}_i^T \Sigma \mathbf{u}_i$$

La méthode mathématique d'optimisation de Lagrange a permis de résoudre ce problème en prouvant que ces vecteurs sont les vecteurs propres de la matrice de variance-covariance .

VECTEURS PROPRES ET VALEURS PROPRES

Les valeurs propres sont les coefficients qui donnent la quantité de variance portée dans chaque axe principal. Ils sont les racines du polynôme caractéristique:

$$p(\lambda) = \det(\Sigma - \lambda I)$$




Les vecteurs propres u de la matrice de Covariance sont les directions des axes où il y a le plus de variance que nous appelons les composantes Principales. On les calcule comme suit:

$$\Sigma u = \lambda u$$

INTERPRÉTATION DES VALEURS ET VECTEURS PROPRES DE LA MATRICE DE COVARIANCE

les vecteurs propres correspondant aux valeurs propres les plus élevées capturent la variance la plus importante des données

Les valeurs propres de la matrice de covariance représentent la quantité de variance expliquée par chaque vecteur propre et indique la quantité de variance des données projetées le long de cette direction.



LES COMPOSANTES PRINCIPALES

En classant vos vecteurs propres par ordre de leurs valeurs propres, de la plus haute à la plus basse, vous obtenez les composantes principales par ordre d'importance.

- Le 1^{er} axe principal est de direction u_1 associé à la plus grande valeur propre λ_1
- Le 2^{ème} axe principal est de direction u_2 associé à la deuxième valeur propre λ_2
- ...
- Le k -ième axe principal est de direction u_k associé à la k -ième valeur propre λ_k

Si on désire une représentation plane des individus , la meilleure sera celle réalisée grâce aux deux premiers axes principaux.

LES NOUVELLES COORDONNÉES

Les nouvelles coordonnées sont les projections aux axes principaux

La 1^{ère} coordonnée C1 est le vecteur de projections des individus sur la 1^{ère} composante principale

$$\mathbf{C}_1 = \mathbf{X}^* \mathbf{u}_1 =$$

$$\begin{bmatrix} x_{11}^* & x_{12}^* & \cdots & x_{1p}^* \\ x_{21}^* & x_{22}^* & & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1}^* & x_{n2}^* & \cdots & x_{np}^* \end{bmatrix} \begin{bmatrix} u_{11} \\ u_{21} \\ \vdots \\ u_{p1} \end{bmatrix} = \begin{bmatrix} x_{11}^* u_{11} + x_{12}^* u_{21} + \cdots + x_{1p}^* u_{p1} \\ x_{21}^* u_{11} + x_{22}^* u_{21} + \cdots + x_{2p}^* u_{p1} \\ \vdots \\ x_{n1}^* u_{11} + x_{n2}^* u_{21} + \cdots + x_{np}^* u_{p1} \end{bmatrix} = \begin{bmatrix} c_{11} \\ c_{21} \\ \vdots \\ c_{n1} \end{bmatrix}$$

Où $\mathbf{X}^*$ est la matrice standardisée

LES NOUVELLES COORDONNÉES

- La 2^{ème} coordonnée C_2 est le vecteur de projection des individus sur la 2^{ème} composante principale
- La k -ème coordonnée C_p est le vecteur de projection des individus sur la k -ème composante principale

On appelle la matrice $\mathbf{C}$, la matrice des données « projetées »
(également de taille $n \times k$)

$$\mathbf{C} = \begin{bmatrix} c_{11} & c_{12} & \dots & c_{1p} \\ c_{21} & c_{22} & & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ c_{n1} & c_{n2} & \dots & c_{np} \end{bmatrix}$$

$C_1 \quad C_2 \quad \quad C_p$

VARIANCE EXPLIQUÉE

$$\text{explained_variance} = \lambda$$

La variance expliquée **est égale à la valeur propre λ_i** de la matrice de covariance associée à cette composante principale **u_i**

Elle mesure la quantité d'information contenue dans chaque composante principale

Elle indique la quantité de variance totale des données d'origine qui est capturée ou "expliquée" par chaque composante principale

PROPORTION DE VARIANCE EXPLIQUÉE


$$\text{Ratio variance expliquée} = \frac{\lambda_i}{\sum_{i=0}^n \lambda_i}$$

- Elle est utilisée pour évaluer l'importance relative de chaque composante dans la représentation des données d'origine.
- Elle indique la proportion de la variance totale des données qui est capturée par chaque composante principale.
- Elle est souvent exprimée en pourcentage.

COMBIEN DE COMPOSANTES GARDER ?

Critère de la variance expliquée

- Tracez le graphique de la proportion de variance expliquée par chaque composante principale en fonction du nombre de composantes
- Choisissez un seuil du total de la variance (ici 90%)
- Garder le nombre qui font passer ce seuil



ÉTAPES DE L'ACP

Standardisation des données : Si les variables présentent des échelles différentes en soustrayant la moyenne de chaque variable et en divisant par l'écart-type. Cela assure que toutes les variables contribuent de manière équitable à l'analyse.

Calcul de la matrice de covariance

Décomposition de la matrice en ses vecteurs propres et ses valeurs propres. Les vecteurs propres sont les composantes principales, et les valeurs propres mesurent les variances expliquées par chaque composante principale

Sélection des composantes principales

Projection des données On projette les données d'origine dans le nouvel espace défini par les composantes principales. Chaque observation est ainsi représentée par ses coordonnées sur ces nouveaux axes.

\ ACP AVEC PYTHON

```

# Importer les librairies
from sklearn.decomposition import PCA
from sklearn.preprocessing import
StandardScaler

# standardiser les données
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

# créer le model de la PCA
pca = PCA(n_components=2)

# appliquer la PCA à la base de donnée
pca.fit(Z)

# projeter les données
x_pca = pca.transform(Z)

# ou bien appliquer la PCA et la projeter
x_pca = pca.fit_transform(Z)

```

```

# Obtenir les composantes principales
pca.components_

# Obtenir les variances expliquées
pca.explained_variance_

# Obtenir les proportions des variances
expliquées

pca.explained_variance_ratio_

# Obtenir les proportions des variances
expliquées cumulées

explained_var = np.cumsum(eigenvalues) /
np.sum(eigenvalues)

```

AVANTAGE DE L'ACP

Réduction de dimensionnalité :

- **Visualisation des données** tracer des données de grande dimension en deux ou trois dimensions, ce qui facilite leur interprétation.
- **Réduction du bruit** : En supprimant les composantes principales à faible variance, censées représenter du bruit
- **Compression des données** : la PCA peut réduire les besoins de stockage et accélérer le traitement.

Multicolinéarité Identifier la structure sous-jacente des données et à créer de nouvelles variables non corrélées qui peuvent être utilisées dans le modèle de régression.

Détection des valeurs aberrantes En recherchant des points de données éloignés des autres points de l'espace des composantes principales.

INCONVÉNIENTS ET LIMITES DE L'ACP

Relations non linéaires ACP = Transformation **linéaire** des données.

Cependant, s'il existe des relations non linéaires entre les variables, l'analyse en composantes principales n'arrivent pas à gérer correctement ces relations.

Interprétation des composantes principales Les composantes principales créées par l'analyse en composantes principales sont des combinaisons linéaires des variables d'origine, et il est souvent difficile de les interpréter en termes de variables d'origine. Cela peut rendre difficile l'explication des résultats de l'ACP à d'autres.

Perte d'informations : Le degré de perte d'informations dépend du nombre de composants principaux sélectionnées. Il est donc important de sélectionner le nombre de composants principales à conserver.

Complexité informatique : le calcul peut être coûteux en termes de calcul pour les grands ensembles de données

BIBLIOGRAPHIE

<https://www.dailydoseofds.com/formulating-the-principal-component-analysis-algorithm-from-scratch/>

<https://medium.com/analytics-vidhya/understanding-k-nearest-neighbour-algorithm-in-detail-fc9649c1d196>

Hastie, Trevor; Tibshirani, Robert and Friedman, Jerome (2009). "The Elements of Statistical Learning (Data Mining, Inference, and Prediction), 2nd edition". New York: "Springer texts in statistics".

Gujarati, Damodar N. (2003). "Basic Econometrics, 4th edition". New York, NY: McGraw Hill. Bishop, C. M. (2006). Pattern Recognition and Machine Learning. Springer.