

Cours rédigé par :

Mathieu SEURIN

mathieu.seurin@devinci.fr

Nancy CHENDEB


Nancy.chendeb@devinci.fr

ALGORITHMES
D'APPRENTISSAGES

-

COURS 4

CLASSIFICATION ET SVM



SUPERVISÉ : 2 CATÉGORIES DE PROBLÈMES

Régression	Classification
Prix d'une maison	Type de fleur présent sur une image
Prédire la quantité de vin produite cette année par un vigneron	Spam or not spam ?
Prédiction du prix d'une action dans 2 heures	Quel est le sentiment dominant dans un texte ?

CLASSIFICATION

- Assigner une étiquette / classe à un exemple $y \in \mathbb{N}$
- Maison : Va être vendue en 1 mois ou non ? (2 classes)
- Sur une image, quel est l'animal présent? (Autant de classes que d'animaux possibles)
- Enregistrement sonore : quelle syllabe ? (Nombre de classes = Nombre de syllabe)
- Quel token suivant ChatGPT prédit ? (Nombre de classes = nombre de token possible)



\ CLASSIFICATION OU RÉGRESSION ?

- A partir d'images IRM, prédire si un patient est atteint d'un cancer.
- Prédire combien de personnes va cliquer sur mon site web
- Dans un jeu, prédire le score d'un joueur à partir des actions qu'il a effectuées.
- Répondre à une question de « Qui veut gagner des millions ? »

CLASSIFICATION BINAIRE (2 CLASSES)

Modèle $f_{\theta}(x) = \hat{y}$

Prédiction $y \in \{0, 1\}$ (0 : non-vendue 1: vendue)

Pourquoi ne pas utiliser la régression linéaire tel que l'on a fait ?

CLASSIFICATION BINAIRE (2 CLASSES)

La régression linéaire prédit des valeurs sur $]-\infty, \infty[$


On aimerait une sortie discrète sur $\{0, 1\}$

Fonction sigmoïde : $s(x) = \frac{1}{1 + e^{-x}}$ sortie entre $[0, 1]$

Régression logistique $f_{\theta}(x) = \frac{1}{1 + e^{-x \cdot \theta}}$

Puis on applique un seuil sur la sortie.

(S'appelle régression, mais c'est bien de la classification !)



PRÉDICTION DU DIABÈTE

$x \cdot \theta$ représente un score que l'on transforme en pseudo-probabilités

Exemple

Poids	Diabète
78	0
120	1
90	0
110	1

$$f_{\theta}(x) = \frac{1}{1 + e^{-(x \cdot \theta)}}$$


$$\theta = [100, -1]$$

\ FONCTION DE COÛT DE LA RÉGRESSION LOGISTIQUE

$$J_{\theta}(x, y) = \begin{cases} -\log(f_{\theta}(x)) \\ -\log(1 - f_{\theta}(x)) \end{cases}$$

si $y = 1$

si $y = 0$



$$J_{\theta}(x, y) = y \times (-\log(f_{\theta}(x))) + (1 - y) \times (-\log(1 - f_{\theta}(x)))$$


$$\nabla J_{\theta}(x, y) = X^T (X\theta - y)$$

Même dérivée que pour la régression linéaire avec les moindres carrés (MSE) !

\ VOUS PRÉFÉREZ QUEL MODÈLE? ILLUSTRATION

Quel modèle a l'air le plus adapté pour séparer les points bleus et rouges ?

Le modèle vert ou le modèle noir ?




\ SVM : RÉGRESSION LINÉAIRE + MARGE

SVM = Support Vector Machine
(machine à vecteur de support)

Objectif:

- Trouver une limite de décision (un hyperplan) qui sépare au mieux les jeux de données
- Maximiser la marge entre les différentes classes



Source de l'image : edureka.com


On suppose les données
linéairement séparables
pour le moment.

CLASSIFICATION AVEC UN SVM

$$y = \begin{cases} 1 & \text{si } x \cdot \theta \geq 0 \\ -1 & \text{si } x \cdot \theta \leq 0 \end{cases}$$

θ est le vecteur orthogonal au plan

$$\begin{aligned} \text{Marge}(H) &= \min_{x_i} d(x_i, H) \\ &= 2 \frac{|x_s \cdot \theta|}{\|\theta\|} \end{aligned}$$



○ Vecteur de support (x_s)

CLASSIFICATION AVEC UN SVM

$$Marge(H) = \min_{x_i} d(x_i, H) = \frac{|x_s \cdot \theta|}{\|\theta\|} \quad k(x \cdot \theta) \geq 0$$

On impose que la marge soit 1 soit : $x_s \cdot \theta = 1$ donc

$$Marge(H) = \frac{2}{\|\theta\|} \quad (\text{on cherche à maximiser la marge})$$

$$\begin{cases} \min_{\theta} \frac{1}{2} \|\theta\|^2 \\ \text{tel que } y_i(x_i \cdot \theta) \geq 1 \quad \forall i \end{cases} \quad (\text{problème primal})$$

MULTIPLICATEUR DE LAGRANGE

$$L(\theta, \alpha) = \frac{1}{2} \|\theta\|^2 - \sum_{i=1}^n \alpha_i [y_i(x \cdot \theta) - 1]$$

s'annule en

$$\frac{\delta}{\delta \theta} L(\theta, \alpha) = 0 \rightarrow \theta = \sum_{i=1}^n \alpha_i y_i x_i$$

$$\text{Problème dual : } \begin{cases} \max_{\alpha} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j \\ \alpha_i \geq 0, \quad \forall i \\ \sum_{i=1}^n \alpha_i y_i = 0 \end{cases}$$

MULTIPLICATEUR DE LAGRANGE

$$L(\theta, \alpha) = \frac{1}{2} \|\theta\|^2 - \sum_{i=1}^n \alpha_i [y_i (x \cdot \theta) - 1]$$

s'annule en

$$\frac{\delta}{\delta \theta} L(\theta, \alpha) = 0 \rightarrow \theta = \sum_{i=1}^n \alpha_i y_i x_i$$


Ce qu'il faut retenir :

α_i sont des poids pour chaque point x_i

La plupart des α_i seront à 0 sauf ceux des vecteurs de supports

Mais comment faire si les points ne sont pas linéairement séparables ?

UTILISATION EN PRATIQUE : MARGE SOUPLE





SVM à marge souple :

$$\min_{\theta} \frac{1}{2} \|\theta\|^2 + C \sum_{i=1}^n \zeta_i$$

Où : $\zeta_i = 1_{\{y_i \neq \hat{y}_i\}} d_i$
 ζ (zeta)

C est le paramètre dans sklearn qui équilibre classification et marge

SI L'HYPÉPLAN N'EST PAS LINÉAIRE?



SVM LINÉAIRE OU NON LINÉAIRE?

- SVM linéaire :
 - Lorsque les données sont séparables linéairement
 - Rapide à faire tourner, bonne baseline.

- SVM non linéaire :
 - Plus long, mais permet d'avoir un modèle plus expressif

Prédiction pour un nouveau point : $f_{\theta}(x) = \sum_{i=1}^S \alpha_i y_i x_i^T x + \theta_0$

Où x_i sont les vecteurs de supports, y_i les labels et α_i

QU'EST CE QU'UN KERNEL?

Kernel = produit scalaire dans un espace à grande dimension (projection + produit scalaire)

$K(x, z) = \langle \phi(x), \phi(z) \rangle$ avec $\phi(z)$ une fonction de projection d'un point.

L'intérêt du kernel est de ne pas avoir à projeter explicitement les points x, z PUIS de calculer le produit scalaire.

Kernel polynomial : $K(x, z) = (x^T \cdot z + 1)^d$ avec d un paramètre ajustable.


Kernel Gaussien : $K(x, z) = e^{-\frac{\|x-y\|^2}{2\sigma^2}}$ avec σ paramètre ajustable

EXEMPLE DU KERNEL POLYNOMIAL


Case 1 - 1 Dimensional Space



Case 2 - 2 Dimensional Space



EXEMPLE DU KERNEL GAUSSIEN



\ SVM OU SVC?

SVM (Support Vector Machine) : Nom général de l'algorithme

SVC (Support Vector Classifier) : Le nom utilisé dans sklearn pour la classification

SVR (Support Vector Regressor) : L'adaptation du SVM pour la régression

\ CRITÈRE D'ÉVALUATION DE LA CLASSIF'

90% de mes points sont bien classés, est-ce que c'est un bon score ou non ?

Si il y a une répartition 95%, 5% non !

Toujours comparer au classifieur qui prédit la classe majoritaire.
Problèmes des classes déséquilibrées.

MATRICE DE CONFUSION

Vrais Positifs (True Positives - TP) : Le modèle a correctement prédit les instances de la classe positive.

Faux Positifs (False Positives - FP) : Le modèle a incorrectement prédit des instances comme appartenant à la classe positive, alors qu'elles appartiennent à la classe négative

Faux Négatifs (False Negatives - FN) : Le modèle a incorrectement prédit des instances comme n'appartenant pas à la classe positive, alors qu'elles appartiennent à la classe positive.

Vrais Négatifs (True Negatives - TN) : Le modèle a correctement prédit les instances de la classe négative.

		<i>Reality</i>	
		Negative : 0	Positive : 1
<i>Prediction</i>	Negative : 0	True Negative : TN	False Negative : FN
	Positive : 1	False Positive : FP	True Positive : TP

\ PRÉCISION ET RAPPEL

La précision mesure la capacité du modèle à éviter de faire des prédictions positives incorrectes
Elle représente le pourcentage d'échantillons correctement classés.

$$\text{Précision (classe } c) = \frac{\text{TP (classe } c)}{\text{TP (classe } c) + \text{FP (classe } c)}$$

Le rappel mesure la capacité du modèle à capturer toutes les occurrences réelles de la classe positive.

$$\text{Rappel (classe } c) = \frac{\text{TP (classe } c)}{\text{TP (classe } c) + \text{FN (classe } c)}$$

SPÉCIFICITÉ

La spécificité mesure la proportion d'observations réellement négatives qui ont été correctement identifiées parmi toutes les observations réellement négatives.

Elle est calculée comme suit:

$$\text{Spécificité (classe } c) = \frac{\text{TN (classe } c)}{\text{TN (classe } c) + \sum_{j \neq c} \text{FP (classe } j)}$$

La spécificité mesure la capacité du modèle à éviter de faire des prédictions positives incorrectes

Une valeur élevée de spécificité indique que le modèle a tendance à identifier correctement la plupart des observations réellement négatives.

La spécificité est souvent utilisée en conjonction la précision, le rappel et le F1 Score, pour obtenir une évaluation globale de la performance d'un modèle de classification

\ F1 SCORE (EN PRATIQUE)

Le F1 Score est une métrique d'évaluation qui combine la précision (precision) et le rappel (recall) en une seule valeur. Il permet d'évaluer à la fois la capacité du modèle à minimiser les faux positifs (précision) et à minimiser les faux négatifs (rappel).

La formule du F1 Score est la suivante :

$$\text{F1 Score} = \frac{2 \cdot \text{Précision} \cdot \text{Rappel}}{\text{Précision} + \text{Rappel}}$$

La performance du modèle est parfaite lorsque F1 Score atteint sa valeur maximale de 1

La performance du modèle est mauvaise lorsque F1 Score atteint sa valeur minimale de 0

Bien mieux lorsqu'il y a des classes déséquilibrées !

CONCLUSION GÉNÉRALE

Classification en utilisant la Régression logistique : Même principe que la régression linéaire, optimisation par descente de gradient.

SVM : Amélioration de la régression linéaire (ajout de la marge)

Permet d'ajouter de la non-linéarité à nos modèles sans expliciter les projections.

Plusieurs critères pour évaluer nos modèles

AVEC PYTHON

```

from sklearn.model_selection import train_test_split
from sklearn.svm import SVC

# Division des données en ensembles d'entraînement et de test
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=42)

# Entraînement du modèle SVM
svm_model = SVC(kernel='linear')
svm_model.fit(X_train, y_train)

# Identification des vecteurs de support
support_vectors = svm_model.support_vectors_
  
```

