

Cours rédigé par :


Nancy CHENDEB

nancy.chendeb@devinci.fr

Mathieu SEURIN

mathieu.seurin@devinci.fr

ANALYSE DE DONNÉES



ÉVALUATION

- Contrôle Continu sur Schooding (25% de la note)
- Projet (25% de la note)
- Examen Final sur Schooding (50% de la note)

✓ RÉFÉRENCE DU COURS



Python DataScience HandBook by Jake Van Der Plas :
<https://jakevdp.github.io/PythonDataScienceHandbook/index.html>

Hands-On-Data-Analysis Book by Stefanie Molin :
<https://github.com/stefmolin/Hands-On-Data-Analysis-with-Pandas-2nd-edition>

MOTIVATION DE L'ANALYSE DE DONNÉES

Un élève : "Pourquoi est-ce que je me suis levé ce matin pour ce cours ?"

\ POURQUOI L'ANALYSE DE DONNÉES ?



Exemples :

- La récolte de pomme de cette année est moins bonne, comment "expliquer" ça ?
- Comment la météo a-t-elle impacté l'hygrométrie des sols ?
- Comment vont évoluer les épidémies sur ma parcelle dans les prochains mois ?
- Est-ce que je peux utiliser l'état de santé de ma plante pour prédire un rendement ?

# Arbre	# Branches	Coordonnées GPS	IMG	Orientation parcelle	Humidité sol
0	20	(10,20)	Image_1.png	W	.32
1	12	(20, 150)	Image_2.png	S	.20



POURQUOI L'ANALYSE DE DONNÉES ?




Objectifs globaux :

- Comprendre la corrélation entre plusieurs événements (on aimerait la causalité, mais c'est plus compliqué ...)
- Faire de la prédiction à partir de données.



État de santé
(Très bon, bon, mauvais)

Rendement (Quantité)



QUELS OUTILS PERMETTENT ÇA ?




- La connaissance du domaine (Scientifique, terrain, métier)

Ce cours

- Des outils statistiques pour analyser le passé (Analyse de corrélation, ACP, Tests (khi2 student etc...) ...)
- Visualisation des informations (analyse qualitative)
- Outil d'apprentissage : Régression / Classification, Linéaire ou non-linéaire, SVM, Arbre de Décision, Réseaux de neurones etc..

CE QU'IL Y A DANS CE COURS




- Apprendre à explorer des données à l'aide de Python et des librairies d'analyse (numpy, pandas, seaborn, matplotlib)
- Comprendre comment utiliser ces données pour faire de la prédiction (Apprentissage machine / statistique)
- Implémenter différents algorithmes d'apprentissage, comprendre dans quels contextes utiliser l'un ou l'autre.
- Apprendre à évaluer différents modèles, les comparer.
- Utiliser des bibliothèques plus "haut niveau" qui implémentent déjà ces algorithmes (sklearn)

\\ CE QU'IL N'Y AURA PAS DANS CE COURS

- Ne traite pas du stockage et de l'accès des données, on les considère facilement accessible et de taille raisonnable pour être traités par une seule machine
- Ne traite pas du déploiement des modèles, de cloud etc...
- Ne traite pas d'un domaine en particulier (vision, langage etc..)
- Ne traite pas de séries temporelles

PLAN GLOBAL



- CM1 : Rappel sur les outils Python (Numpy, Pandas, Matplotlib, Seaborn)
- CM2 : Analyse en composantes principales (ACP ou PCA en Anglais)
- CM3 : Descente de gradient et ses variations
- CM4 : Machine à Vecteur de support (SVM)
- CM5 : Description du projet
- CM6 : Arbre de décision

CMO 1 : MOTIVATION, RAPPEL SUR NUMPY, PANDAS, MATPLOTLIB, SEABORN

À regarder avec le notebook CM1_Rappel.ipynb associé

PLAN DU JOUR

- Contexte de l'analyse de Données
- Rappel sur Numpy
- Rappel sur Pandas
- Rappel sur Matplotlib et Seaborn

CONTEXTE ANALYSE DE DONNÉES

Dans la peau d'un datascientist :

- Analyse Qualitative des données disponibles
(EDA = Exploratory Data Analysis)
- Création de modèle de prédiction
- Retour sur les données
- Re-cr ation de mod le
- Etc...

Exemple : Pr diction de match de foot chez Betclic



EXEMPLE PRÉDICTION DE MATCH DE FOOT

Vous avez des données sur :

- Les joueurs avec des stats
 - poste, nb de buts, placement pour le prochain match
- Les historiques des rencontres
- Des stats pour les matchs :
 - À domicile vs À l'extérieur
 - Les actions réalisées pendant les matchs
 - (Cartons, nombre de corners etc..)

Vous devez prédire le résultat du match ensuite.



APPRENTISSAGE ? = LA PARTIE « MODÈLE »

Prix équipe 1	Prix équipe 2
1M	3M
10k	3M
200K	1M
30K	10K
0	3M

X

Modèle

Trouver la fonction
(modèle) qui
prédit Y à partir de
 X

Résultat
1 Gagne
Nul
2 gagne
1 gagne
2 gagne

y

$$n = 5$$

Nombre d'exemples

$$k = 2$$


Nombre de caractéristiques

PIPELINE CLASSIQUE DU PROJET

- Analyse Qualitative des données disponibles
 - = Regarder quels sont les facteurs qui ont l'air d'influencer une victoire
 - = Regarder les stats des joueurs, faire des affichages
- Création de modèles de prédiction
 - = Garder les caractéristiques qui sont importantes
 - = Créer des caractéristiques qui peuvent permettre une meilleure prédiction
 - = Tester différents modèles (Arbre de Décision, Réseaux de Neurones etc..)
- Retour sur les données
- Re-crédation de modèle

BONNES PRATIQUES

- Bien définir la tâche que l'on souhaite résoudre : Qu'est-ce qu'on prédit ?
- Définir un score = précision de la prédiction
 - Nombre de bonnes classifications des matchs
 - Quantité en kg de pommes récoltées
- Séparation train / test / validation
 - Pour tester la généralisation du modèle !
 - Exemple : Vos partiels!



TROP DE CARACTÉRISTIQUES ?

Si un modèle a trop d'informations en entrée cela pose plusieurs problèmes :

- Plus de temps à entraîner un modèle
 - « Gestion » de plus de caractéristiques
 - Le temps d'entraînement dépend de la taille des données
- Possible sur-apprentissage (on verra quels modèles peuvent sur-apprendre ou non)

Biais inductif : Biais que l'on introduit (ou qui fait partie d'un modèle) qui accélère la généralisation d'un modèle.

CONCLUSION DE ÇA

Il faut :

- Être à l'aise à la manipulation de données (potentiellement beaucoup d'informations à gérer)
 - Savoir utiliser numpy et pandas
- Pouvoir visualiser des informations
 - Savoir utiliser matplotlib et seaborn
- Savoir construire et comparer des modèles de prédiction de manière rigoureuse
 - Les CMOs suivants et le projet !

\ PLAN NUMPY



- Pourquoi les arrays ?
- Accès, propriétés des arrays et création
- Fonctions diverses et variées de Numpy et Scipy
- Produit, vectoriel, matriciel
- Allocation mémoire
- Broadcasting et piège de numpy

LES LISTES EN PYTHON



- Permet de stocker une collection d'éléments

```
ma_liste= [1,2,3,4]
```

- Typage dynamique donc, liste potentiellement hétérogène

```
ma_liste = [True, "2", 3.0, 4]
```

- Conséquence : Beaucoup de place en mémoire (pour chaque case, python doit stocker le type de l'objet)

\ POURQUOI UTILISER NUMPY ?



- Efficacité de stockage
- Permet d'agir sur de multiples éléments (slices ou l'intégralité de l'array) bien plus aisément
 - (Faire une moyenne sur l'entièreté de l'array simplement ou calcul de variance)
- Plus rapide globalement que les boucles en python

Quand on peut, on vectorise !

\ PRINCIPAUX TYPES EN NUMPY



- `bool_` : 0 ou 1
- `int32` : -2147483648 to 2147483647
- `uint64` Unsigned integer (0 to 18446744073709551615)
- `float64` : sign bit, 11 bits exponent, 52 bits mantissa
- `complex64` : complex number, represented by two 32-bit floats

Et toutes les variations (`int64`, `float32`, `complex128` etc..)

- <https://www.positron-libre.com/cours/electronique/systeme-numeration/nombre-virgule-flottante.php>
- https://www.idpoisson.fr/perrollaz/cours_python/10.html

\ RAPPEL PANDAS




- Numpy travaille avec des np.array
- Pandas avec des DataFrames (et des Series qui sont des arrays 1D mais plus généraux et flexibles)

Un DataFrame est un hybride entre un numpy array et un dictionnaire

Comme numpy, la quasi-totalité des opérations renvoie un nouveau DataFrame (pas de modifications "inplace")

RAPPEL MATPLOTLIB ET SEABORN



Présentation rapide avec le notebook associé

